Reproduction et Extension Méthodologique de MM-ArgFallacy2025

Détection Multimodale de Sophismes dans les Débats Politiques

Boutheina Chebouti
Ingenieur IA

Avril 2026

Résumé

Ce rapport présente la reproduction des baselines de la shared task MM-ArgFallacy2025 sur la détection et classification multimodale de fallacies argumentatives dans les débats politiques américains. En utilisant MAMKit 0.1.1 sur le corpus MM-USED-Fallacy (1 278 instances AFC, 17 118 instances AFD, 35 dialogues), nous reproduisons les baselines texte (RoBERTa, macro F1 = 0,476 AFC ; binary F1 = 0,308 AFD) et multimodales (WavLM + RoBERTa, macro F1 = 0,445 AFC sur 35 folds LODO), sans gain statistiquement significatif de la fusion multimodale ($p = 0{,}565$).Nos scores apparaissent numériquement proches des baselines du papier (AFC texte : 0,393 ; AFD texte : 0,277 ; AFC multimodal : 0,382 ; AFD multimodal : 0,285), mais cette observation n'a pas de valeur comparative en l'absence d'évaluation sur le test set secret — elle indique seulement que notre reproduction atteint un régime de performance cohérent sur un protocole alternatif. Parmi les stratégies testées, la weighted cross-entropy surpasse systématiquement la focal loss (F1 = 0,188 vs 0,476), confirmant son adéquation au double déséquilibre de cette tâche. Un audit original de la qualité d'alignement audio-texte révèle que 51,6% des clips sont bien alignés et que le misalignment est principalement fonctionnel le contexte acoustique apporte une information paralinguistique utile plutôt que du bruit. Une analyse XAI combinant attention, gradient saliency et SHAP révèle un shortcut learning sur les folds difficiles et confirme qu'Appeal to Emotion agit comme attracteur dominant ($r = -0{,}642$, $p < 0{,}001$ entre force du texte et gain multimodal). L'extension méthodologique sur le contexte dialogique ciblé ($k = 1$, 35 folds) ne démontre pas de gain significatif ($p = 0{,}280$) mais apporte des gains locaux sur Ad Hominem et Slippery Slope, confirmant que le contexte dialogique contient un signal utile mais inexploitable par une fusion naïve. Ces résultats ouvrent des perspectives pour une thèse sur l'analyse multimodale des débats politiques, notamment via une cross-attention token-frame guidée par les timestamps Whisper et un apprentissage multi-tâches.

[1]

1. Le code source est disponible sur : `https://github.com/bouth-ch/mm-argfallacy2025`

Table des matières

1 Introduction **4**

2 Analyse Critique de MM-ArgFallacy2025 **4**
2.1 Contributions du papier . . . 4
2.2 Analyse des résultats par modalité . . . 4
2.3 Pourquoi la multimodalité apporte des gains limités . . . 5
2.4 Le rôle du déséquilibre des classes . . . 5
2.5 Positionnement par rapport à l'état de l'art . . . 5

3 Description Expérimentale **5**
3.1 Dataset et préparation des données . . . 5
3.2 Protocole d'évaluation . . . 6
3.3 Modèles et hyperparamètres . . . 6
3.4 Gestion du déséquilibre des classes . . . 7

4 Résultats **7**
4.1 Argumentative Fallacy Classification (AFC) . . . 7
4.1.1 Baseline texte — AFC . . . 7
4.1.2 Baseline multimodale . . . 9
4.1.3 Extension — Contexte dialogique ciblé (N-1) . . . 11
4.1.4 Comparaison des trois modèles . . . 11
4.2 Argumentative Fallacy Detection (AFD) . . . 12
4.2.1 Baseline texte . . . 13
4.2.2 Baseline multimodale . . . 13
4.3 Synthèse comparative . . . 13

5 Discussion, Perspectives et Conclusion **14**

Annexe **15**

Table des figures

1 Distribution des classes dans notre dataset d'entraînement (MAMKit 0.1.1). **Gauche** : AFC Appeal to Emotion représente 62,6% des instances (800/1 278). **Droite** : AFD 90,8% des phrases sont non-fallacieuses (15 550/17 118). . . . 6

2 **Gauche** : Classification des clips audio selon la qualité d'alignement. **Droite** : Similarité sémantique globale. . . . 6

3 **Gauche** : macro F1 AFC par fold (35 folds LODO). **Droite** : distribution du nombre de classes par fold les folds à une seule classe produisent des F1 extrêmes. . . . 7

4 **Gauche** : F1 par classe agrégé sur 35 folds. **Droite** : matrice de confusion Appeal to Emotion absorbe 56% des Slogans, 43% des Slippery Slope et 32% des False Cause. . . . 7

5 Analyse XAI contrastive. **Gauche** : gradient saliency sur le meilleur fold (`22_1996`) mots sémantiquement discriminants. **Droite** : attention sur un fold difficile (`20_1992`) shortcut learning sur mots fonctionnels. . . . 8

6 Valeurs SHAP pour le fold moyen (`20_1992`) : prédictions correctes sur tokens pertinents, erreurs sur tokens génériques. . . . 9

7 Qualité audio par fold vs F1 multimodal AFC. L'absence de corrélation confirme que la variance est d'origine linguistique. . . . 9

8 RoBERTa texte vs WavLM+RoBERTa sur 35 folds triés par F1 texte croissant. **Haut** : F1 par fold. **Bas** : Δ F1 (MM $-$ texte). Trois zones : texte faible (vert) où MM aide légèrement, texte moyen (jaune) où MM est neutre, texte fort (rouge) où MM dégrade ($r = -0{,}642$, $p < 0{,}001$). . . . 10

9 Matrice de confusion agrégée sur 35 folds WavLM + RoBERTa (AFC). Appeal to Emotion reproduit le même pattern attracteur qu'en texte seul. . . . 10

10 Analyse différentielle des erreurs : WavLM+RoBERTa vs RoBERTa texte. **Gauche** : régression vs gain MM par classe. **Centre** : erreurs MM (texte OK $\rightarrow$ MM KO, $n = 491$). **Droite** : gains MM (texte KO $\rightarrow$ MM OK, $n = 153$). . . . 11

11 F1 par classe Text vs MM vs MM $k = 1$ (35 folds LODO). Le texte seul domine sur la majorité des classes. Slippery Slope est la classe la plus dégradée par la fusion audio. . . . 12

12 Forest plot des différences de F1 avec IC bootstrap 95% (35 folds LODO-CV). Tous les IC contiennent 0 aucune comparaison n'est statistiquement significative. . . . 12

13 **Gauche** : binary F1 AFD par fold (35 folds LODO). **Droite** : matrice de confusion AFD le modèle prédit majoritairement non-fallacieux. . . . 13

1 Introduction

L'argument mining (AM) vise à extraire automatiquement des arguments et leurs relations à partir de sources en langage naturel [Lippi and Torroni, 2016]. Parmi les nombreux domaines explorés en AM, les débats politiques constituent un terrain particulièrement riche, permettant des applications concrètes telles que la détection de sophismes, l'analyse de la persuasion et l'évaluation de la cohérence argumentative des candidats [Haddadan et al., 2019, Goffredo et al., 2022]. Si les premières approches en AM se sont concentrées sur le texte, des travaux récents ont commencé à intégrer la modalité audio dans l'analyse des débats politiques [Mancini et al., 2022, Mestre et al., 2023], motivés par l'hypothèse que les indices paralinguistiques comme l'intonation, le rythme, l'intensité vocale peuvent enrichir la détection des composantes argumentatives [Kišiček, 2020]. C'est dans ce contexte que s'inscrit MM-ArgFallacy2025 [Mancini et al., 2025], une shared task co-localisée avec le 12e Workshop on Argument Mining à ACL 2025, qui propose pour la première fois une évaluation standardisée de la détection et classification de sophismes argumentatifs en modalité texte, audio et multimodale sur des débats présidentiels américains. Ce rapport présente notre reproduction des baselines de la shared task, une analyse critique approfondie des résultats par modalité, ainsi qu'une extension méthodologique originale portant sur la qualité de l'alignement audio-texte et l'intégration du contexte dialogique.

2 Analyse Critique de MM-ArgFallacy2025

2.1 Contributions du papier

MM-ArgFallacy2025 [Mancini et al., 2025] est une shared task organisée pour la première fois, co-localisée avec le 12e Workshop on Argument Mining à ACL 2025. Elle propose deux sous-tâches complémentaires : l'**AFD** (détection binaire la phrase contient-elle une fallacy ?) et l'**AFC** (classification multi-classes parmi six catégories : Ad Hominem, ex. *"Mon adversaire ne connaît rien"* ; Appeal to Emotion, ex. *"Pensez à vos enfants"* ; Appeal to Authority ; False Cause ; Slippery Slope ; et Slogan). Pour chaque sous-tâche, trois modes d'entrée sont évalués : text-only, audio-only et text+audio.

Le corpus principal est MM-USED-Fallacy [Mancini et al., 2024b], comprenant 18 925 instances AFD et 3 388 AFC, issu de débats présidentiels américains et accessible via MAMKit un toolkit Python open-source qui construit dynamiquement les datasets multimodaux en contournant les restrictions de copyright sur les enregistrements audio. Cinq équipes ont participé, utilisant principalement des variantes RoBERTa avec des stratégies variées : data augmentation guidée par prompts, intégration du contexte dialogique, fonctions de perte spécialisées et fusion multimodale. Pour l'audio, les approches ont varié des features MFCC aux modèles pré-entraînés comme WavLM [Chen et al., 2022]. Le secret test set est constitué des débats Trump-Biden (28 juin 2024) et Trump-Harris (11 septembre 2024), annotés par deux experts avec un accord inter-annotateurs modéré (kappa = 0,4787 AFD ; 0,4954 AFC), reflétant la difficulté intrinsèque de la tâche, même pour des humains.

2.2 Analyse des résultats par modalité

Les résultats montrent une dominance claire de la modalité textuelle : le meilleur score en text-only atteint 0,4856 de macro F1 pour l'AFC. Cela n'est pas surprenant, car les fallacies sont des constructions logiques et sémantiques naturellement ancrées dans le contenu linguistique des phrases.

L'audio seul obtient des scores inférieurs au texte (0,3559 pour Pittiglio [2025]), mais il serait erroné de le considérer comme inutile. La modalité audio capture des informations paralinguistiques importantes que le texte ne peut pas transmettre : l'intonation, le rythme, l'intensité vocale, le stress ou encore l'humeur du locuteur. Par exemple, une phrase comme *"Mon adversaire est incroyable"* peut sembler neutre à l'écrit, mais prononcée avec une intonation ironique, elle devient un Ad Hominem. La voix trahit souvent ce que les mots cachent.

Cependant, la fusion text+audio ne bat pas systématiquement le text-only : Pittiglio [2025] obtient 0,4403 en multimodal contre 0,4444 en text-only. Cela implique que le problème ne vient pas de la modalité audio en elle-même, mais de la qualité de la fusion entre les deux modalités. Les modèles actuels ne savent pas encore exploiter pleinement l'information audio pour la détection de fallacies, ouvrant ainsi une direction de recherche importante.

Pour la tâche AFD, les résultats suivent un pattern similaire mais plus marqué. La baseline Transformer atteint 0,2770 en binary F1 en text-only, contre 0,2848 en multimodal un gain marginal de moins d'1 point. Fait particulièrement révélateur, les baselines audio-only échouent complètement sur l'AFD (F1=0,000), contre 0,0643 pour l'AFC. Cela suggère que la détection binaire de sophismes est encore plus dépendante du contenu textuel que la classification multi-classes probablement parce que distinguer une phrase fallacieuse d'une phrase non-fallacieuse repose quasi-exclusivement sur des indices sémantiques et syntaxiques.

2.3 Pourquoi la multimodalité apporte des gains limités

Trois facteurs expliquent pourquoi la fusion multimodale n'apporte que des gains limités dans cette tâche. Premièrement, la nature même des fallacies est principalement lexicale et logique. Des catégories comme Slogan ou Ad Hominem se reconnaissent presque entièrement à travers les mots choisis, indépendamment de la prosodie. Seul Appeal to Emotion peut bénéficier de l'audio dans des cas spécifiques, lorsque l'ironie vocale change le sens apparent d'une phrase. Deuxièmement, les stratégies de fusion sont majoritairement naïves. La concaténation des embeddings texte et audio place les deux représentations côte à côte sans modéliser leurs interactions profondes. Les espaces de représentation étant hétérogènes, les fusionner brutalement introduit du bruit plutôt que de la complémentarité. Troisièmement, l'audio peut introduire des biais néfastes via le shortcut learning : le modèle associe systématiquement une voix émotionnelle à Appeal to Emotion, sur-prédisant cette classe au détriment des autres, au lieu de raisonner sur la structure logique de la fallacy

2.4 Le rôle du déséquilibre des classes

Le déséquilibre des classes constitue un défi majeur identifié par Mancini et al. [2025]. Pour l'AFC, Appeal to Emotion domine avec 142 instances sur 229 (62%) dans le secret test set, tandis que Slippery Slope est complètement absente rendant son F1 mathématiquement indéfini. Pour l'AFD, le déséquilibre est encore plus sévère : 90,8% des phrases sont non-fallacieuses contre seulement 9,2% de phrases fallacieuses, ce qui justifie le recours au binary F1 plutôt qu'à l'accuracy un modèle naïf prédisant systématiquement "non-fallacieux" obtiendrait 90,8% d'accuracy sans rien apprendre. Face à ce double déséquilibre, les auteurs ont choisi le macro F1 pour l'AFC et le binary F1 pour l'AFD : ces métriques traitent équitablement toutes les catégories, pénalisant sévèrement un modèle qui prédirait uniquement Appeal to Emotion malgré une accuracy élevée.

2.5 Positionnement par rapport à l'état de l'art

MM-ArgFallacy2025 s'inscrit dans une lignée de travaux progressifs sur l'argument mining dans les débats politiques. Haddadan et al. [2019] ont posé les fondations en construisant le dataset USElecDeb60to16, annoté en premises et claims à partir de 50 ans de débats présidentiels américains, mais uniquement en text-only et sans architectures Transformer. Goffredo et al. [2022] ont étendu ce travail en introduisant les 6 catégories de fallacies qui structurent encore aujourd'hui la taxonomie de MM-ArgFallacy2025, et en proposant une architecture basée sur Longformer, toujours en text-only. Mancini et al. [2022] ont franchi une étape supplémentaire en créant MM-USED, le premier dataset multimodal pour l'argument mining dans les débats politiques. Enfin, Mancini et al. [2024b] ont spécifiquement étendu ce travail à la classification de fallacies en contexte multimodal.Plus récemment, Pittiglio [2025] a proposé l'intégration de contexte dialogique via cross-attention et un ensemble RoBERTa+HuBERT avec optimisation bayésienne, représentant l'approche multimodale la plus sophistiquée soumise à MM-ArgFallacy2025.

Par rapport à ces travaux, MM-ArgFallacy2025 apporte plusieurs contributions nouvelles. C'est la première évaluation standardisée et ouverte comparant simultanément les trois modalités text-only, audio-only et multimodal sur un test set secret constitué de débats contemporains de 2024, garantissant ainsi une évaluation rigoureuse et non biaisée.

Cependant, deux limites principales ouvrent des perspectives de recherche futures. D'une part, les techniques de fusion actuelles restent insuffisantes : entraîner les encodeurs texte et audio séparément empêche le modèle d'apprendre des interactions profondes entre les deux modalités. D'autre part, l'audio contient des informations paralinguistiques riches intonation, stress, ironie qui restent largement inexploitées, suggérant que des architectures de fusion plus sophistiquées pourraient significativement améliorer les performances.

3 Description Expérimentale

3.1 Dataset et préparation des données

Le dataset principal utilisé est MM-USED-Fallacy [Mancini et al., 2024b], accessible via MAMKit version 0.1.1 [Mancini et al., 2024a]. Dans cette version, il comprend 1 278 instances pour l'AFC et 17 118 pour l'AFD, issues de 35 dialogues de débats présidentiels américains couvrant la période 1960–2016. Ces chiffres diffèrent de ceux reportés dans le papier MM-ArgFallacy2025 (3 388 AFC ; 18 925 AFD) car la shared task utilise une version mise à jour intégrant l'amélioration de l'alignement texte-audio via WhisperX [Bain et al., 2023], permettant de récupérer des débats précédemment exclus.

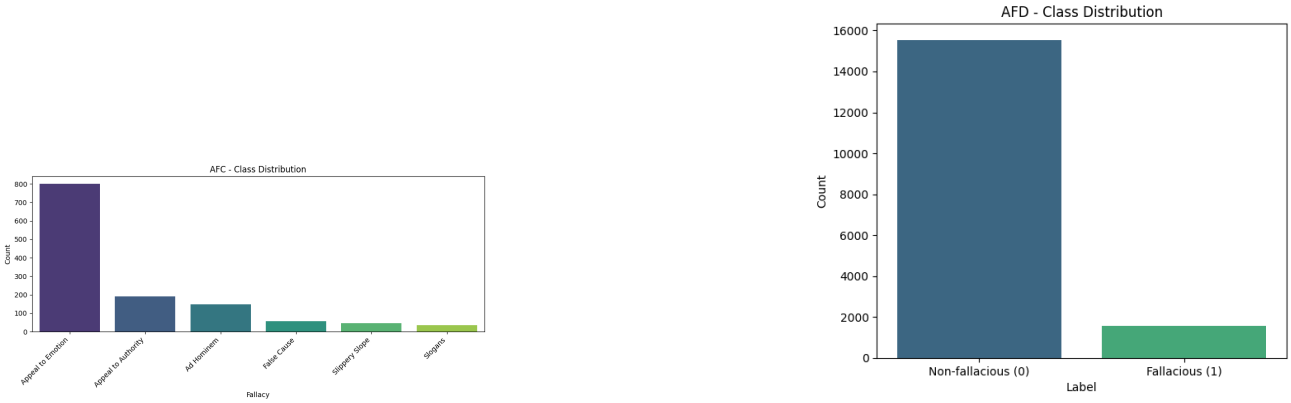

FIGURE 1 – Distribution des classes dans notre dataset d'entraînement (MAMKit 0.1.1). **Gauche** : AFC Appeal to Emotion représente 62,6% des instances (800/1 278). **Droite** : AFD 90,8% des phrases sont non-fallacieuses (15 550/17 118).

Nous avons conduit un audit de qualité audio sur l'ensemble du dataset, combinant le Word Error Rate (WER) calculé via transcription Whisper et un score d'overlap textuel. Cet audit révèle que 51,6% des clips sont bien alignés (WER $\leq$ 0,2 et match score $\geq$ 0,8), tandis que 31,8% présentent un misalignment partiel (BadAlignment), 10,6% sont trop courts (TooShort) et 6,0% trop longs (TooLong). L'analyse de similarité sémantique montre néanmoins que 83% des clips présentent une similarité sémantique supérieure à 0,8, indiquant que le contenu sémantique est globalement préservé.

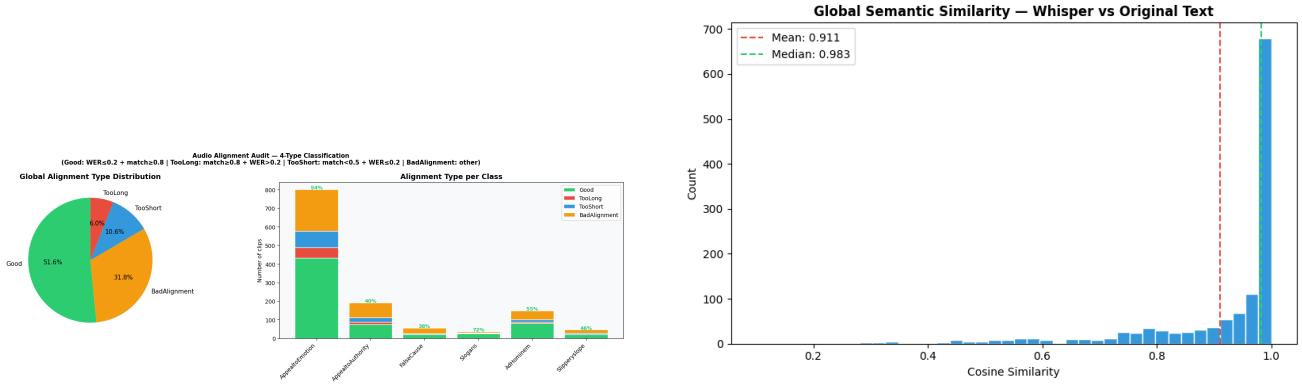

FIGURE 2 – **Gauche** : Classification des clips audio selon la qualité d'alignement. **Droite** : Similarité sémantique globale.

3.2 Protocole d'évaluation

Validation croisée leave-one-dialogue-out (LODO) sur les 35 dialogues [Mancini et al., 2024b], avec macro F1 pour l'AFC et binary F1 pour l'AFD (`zero_division=0`). Les baselines texte et multimodale principale sont évaluées sur les 35 folds complets. Les expériences exploratoires sont conduites sur 5 folds disposant de clips audio alignés leurs résultats détaillés sont en Annexe.

3.3 Modèles et hyperparamètres

Baseline texte. RoBERTa-base [Liu et al., 2019] est utilisé comme encodeur textuel, avec masked mean-pooling sur les hidden states du dernier layer (768d) passé dans une tête de classification linéaire.

Baseline multimodale. WavLM-base [Chen et al., 2022] encode l'audio via un BiLSTM (hidden size 128, bidirectionnel, 256d) concaténé à l'embedding textuel (768d) pour former un vecteur de 1 024d. L'asymétrie 768d/256d reflète la hiérarchie naturelle des modalités.

Extension contexte $k = 1$. `ContextMMUSEDFallacy(k=1)` concatène le tour précédent au snippet cible avant tokenisation, avec les mêmes encodeurs que la baseline multimodale.

Hyperparamètres communs. Adam, lr $= 10^{-5}$, weight decay $= 10^{-5}$, batch size 8, 20 epochs max, early stopping (patience 5), dropout 0,1, graine 42 réinitialisée à chaque fold.

Analyses complémentaires. Quatre expériences exploratoires supplémentaires ont été conduites sur 5 folds (audio découpé, transcription Whisper, contexte dialogique complet, Longformer) pour orienter le choix du contexte $k = 1$. Leurs résultats détaillés sont disponibles en Annexe.

3.4 Gestion du déséquilibre des classes

Weighted cross-entropy loss avec poids. Pour l'AFC : $[0.27, 1.12, 1.43, 3.80, 4.63, 5.92]$ Slogans 22× plus pénalisé qu'Appeal to Emotion. Pour l'AFD : $[0.55, 5.46]$. La focal loss [Lin et al., 2017] a été testée mais dégrade significativement (F1 = 0,188 texte, 0,238 multimodal), confirmant l'adéquation de la weighted loss au double déséquilibre de cette tâche.

4 Résultats

Cette section présente les résultats obtenus sur les deux tâches AFC et AFD, organisés par tâche puis par modalité. Chaque sous-section présente d'abord la baseline texte avec une analyse qualitative et XAI, puis la baseline multimodale, et enfin l'extension méthodologique sur le contexte dialogique ciblé.

4.1 Argumentative Fallacy Classification (AFC)

L'AFC est une classification multi-classes sur six catégories de fallacies. Nous présentons successivement la baseline texte, la baseline multimodale et l'extension contexte N-1, toutes évaluées en LODO-CV sur 35 folds.

4.1.1 Baseline texte — AFC

Le modèle RoBERTa fine-tuné en text-only obtient un macro F1 de 0,476 (± 0,180) sur l'AFC, en moyenne sur 35 folds LODO.

Variance inter-folds. La forte variance reflète l'hétérogénéité structurelle du corpus (Figure 3) : certains dialogues contiennent une seule classe de fallacy le modèle obtient alors F1 = 1,0 mécaniquement. À l'inverse, les dialogues avec 5 ou 6 classes représentées mais peu d'exemples produisent des F1 proches de 0. Cette variance est une propriété du dataset, pas une instabilité du modèle.

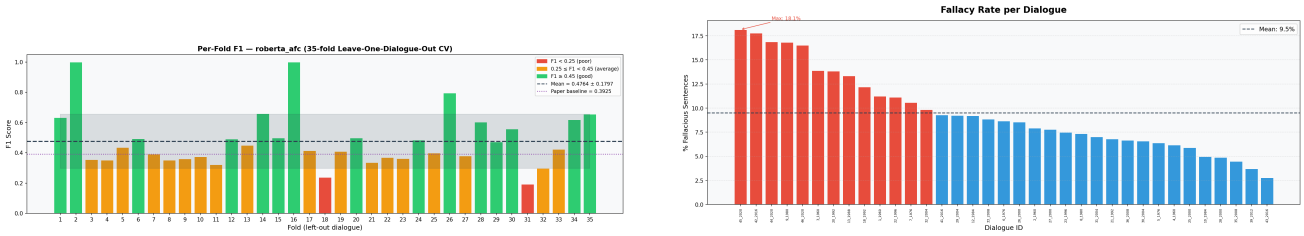

FIGURE 3 – **Gauche** : macro F1 AFC par fold (35 folds LODO). **Droite** : distribution du nombre de classes par fold les folds à une seule classe produisent des F1 extrêmes.

Analyse par classe. Appeal to Emotion obtient le meilleur recall (0,71) tandis que Slogan (F1 ≈ 0,21) et False Cause (F1 ≈ 0,18) restent très difficiles. Une analyse de la longueur des snippets révèle une corrélation partielle : les classes à snippets courts comme Slogan (médiane ≈ 15 mots) et Ad Hominem (médiane ≈ 20 mots) obtiennent les F1 les plus faibles. Cette relation n'est pas universelle False Cause présente des snippets plus longs mais un F1 faible en raison de sa rareté.

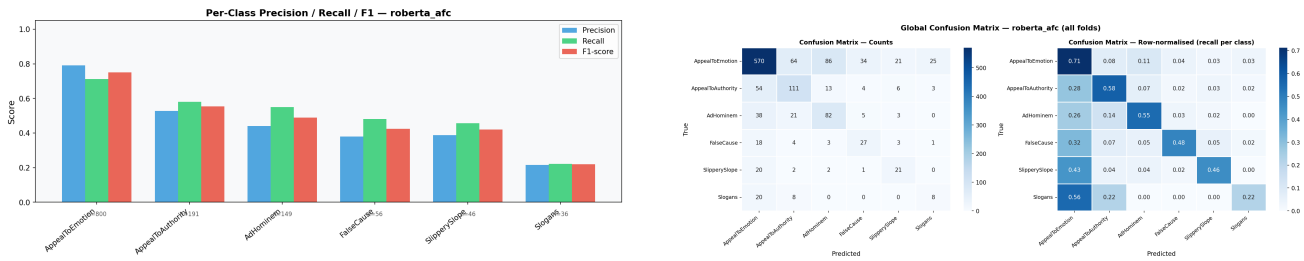

FIGURE 4 – **Gauche** : F1 par classe agrégé sur 35 folds. **Droite** : matrice de confusion Appeal to Emotion absorbe 56% des Slogans, 43% des Slippery Slope et 32% des False Cause.

Exemples d'erreurs. L'examen des erreurs confirme ce pattern. Un snippet prédit *Appeal to Emotion* au lieu de *False Cause* :

> *"It would, of course, be a very serious situation if we had evidence, credible evidence, that Saddam Hussein was developing weapons of mass destruction."* (vrai label : FalseCause)

Serious situation suffit à attirer la prédiction vers Appeal to Emotion, masquant la causalité implicite. Un second exemple, *Ad Hominem* prédit *Appeal to Emotion* :

> *"And the thought that we would share this with the Soviet Union is, in my opinion, a total non-STARTer."* (vrai label : AdHominem)

In my opinion et l'emphase tonique masquent l'attaque personnelle implicite.

Analyse XAI. Pour comprendre le comportement interne du modèle, nous combinons trois méthodes : attention du dernier layer, gradient saliency et SHAP (partition explainer).

Sur le meilleur fold (`22_1996`, F1 = 1,0), le gradient saliency montre que le modèle se concentre sur des mots discriminants : *"nurses"*, *"Nobel"*, *"Gingrich"* pour Appeal to Emotion, Appeal to Authority et Ad Hominem respectivement (Figure 5). Sur les folds difficiles (`20_1992`, F1 = 0,422 et `5_1976`, F1 = 0,192), l'attention se rabat sur des mots fonctionnels *"said"*, *"But"*, *"."*. Ce shortcut learning explique des erreurs comme *"But don't just sit here slow dancing for 4 years doing nothing"* (vraie Appeal to Emotion) prédite Ad Hominem.

L'analyse SHAP (Figure 6) confirme ce biais : les prédictions correctes s'appuient sur des tokens pertinents *"gun"* pour False Cause, *"Republicans"* pour Appeal to Authority tandis que les erreurs sont dominées par des tokens génériques (*"fight"*, *"children"*, *"dream"*). Ces observations sont cohérentes avec l'IAA modéré du papier (0,411 pour Appeal to Emotion) : le modèle reproduit la difficulté humaine de la tâche.

FIGURE 5 – Analyse XAI contrastive. **Gauche** : gradient saliency sur le meilleur fold (`22_1996`) mots sémantiquement discriminants. **Droite** : attention sur un fold difficile (`20_1992`) shortcut learning sur mots fonctionnels.

FIGURE 6 – Valeurs SHAP pour le fold moyen (`20_1992`) : prédictions correctes sur tokens pertinents, erreurs sur tokens génériques.

4.1.2 Baseline multimodale

Sur les 35 folds LODO, WavLM + RoBERTa obtient un macro F1 de 0,445 (± 0,183), en dessous de la baseline texte (0,476 ± 0,180), confirmant la dominance textuelle à l'échelle du corpus complet.

Origine de la variance. L'analyse de la qualité audio révèle une absence de corrélation entre qualité acoustique et F1 multimodal (Figure 7) : le fold `25_2000`, meilleure qualité (WER = 0,235), obtient le F1 le plus bas (0,430), tandis que `22_1996`, qualité la plus faible (WER = 0,299), obtient le meilleur F1 (0,575). La variance est donc d'origine linguistique distribution des classes et style rhétorique plutôt qu'acoustique.

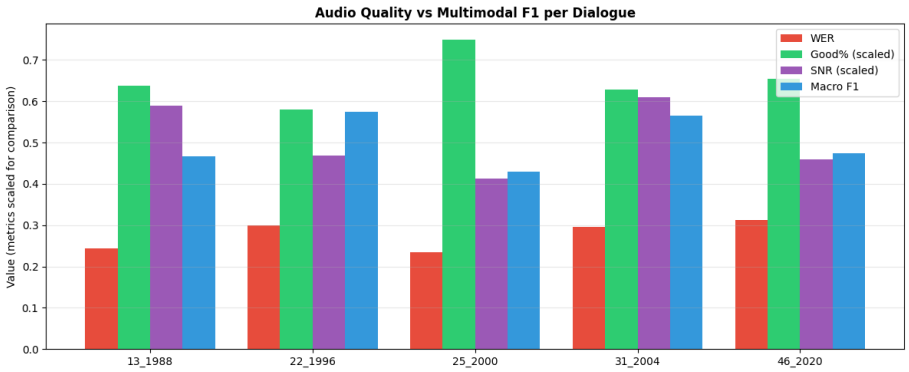

FIGURE 7 – Qualité audio par fold vs F1 multimodal AFC. L'absence de corrélation confirme que la variance est d'origine linguistique.

Effet de la force du signal textuel. Une analyse fold par fold révèle que le gain multimodal est corrélé négativement avec la performance texte ($r = -0{,}642$, $p < 0{,}001$) : plus le texte est discriminant, plus l'audio nuit. Trois régimes se distinguent (Figure 8) :

- **Texte faible** (folds 1–15) : MM apporte un gain modeste le signal audio compense partiellement les lacunes textuelles.
- **Texte moyen** (folds 16–31) : MM est neutre les deux modalités se compensent sans synergie.
- **Texte fort** (folds 32–35) : MM dégrade fortement (Δ moyen $= -0{,}316$) l'audio introduit du bruit redondant quand le texte suffit à discriminer la fallacy.

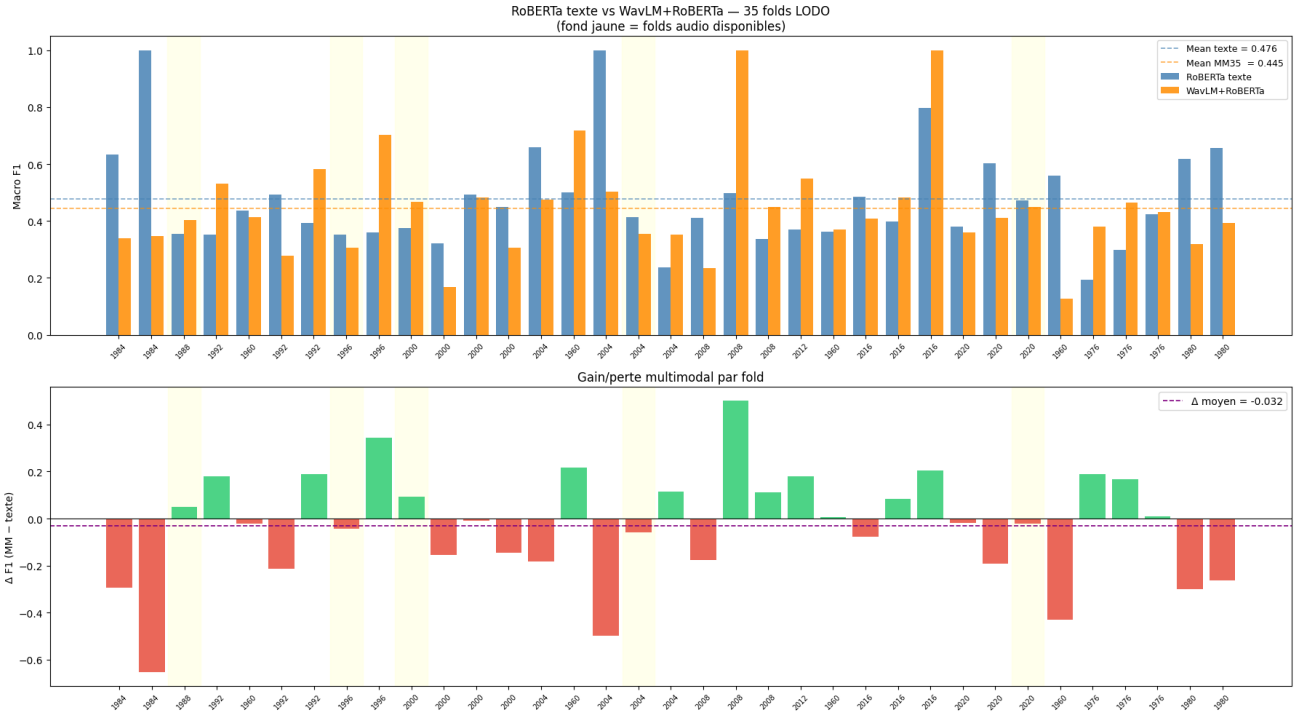

FIGURE 8 – RoBERTa texte vs WavLM+RoBERTa sur 35 folds triés par F1 texte croissant. **Haut** : F1 par fold. **Bas** : Δ F1 (MM − texte). Trois zones : texte faible (vert) où MM aide légèrement, texte moyen (jaune) où MM est neutre, texte fort (rouge) où MM dégrade ($r = -0{,}642$, $p < 0{,}001$).

Pattern d'erreurs. La matrice de confusion (Figure 9) révèle que le modèle multimodal reproduit le même shortcut learning qu'en texte seul : Appeal to Emotion absorbe la majorité des erreurs (recall = 0,66, precision = 0,80), tandis que les classes rares restent difficiles (Slogans F1 = 0,23). La fusion late par concaténation n'apporte pas d'information complémentaire elle reproduit les biais textuels avec une modalité supplémentaire. Ce résultat suggère que la redondance des modalités, et non leur complémentarité, domine dans cette architecture.

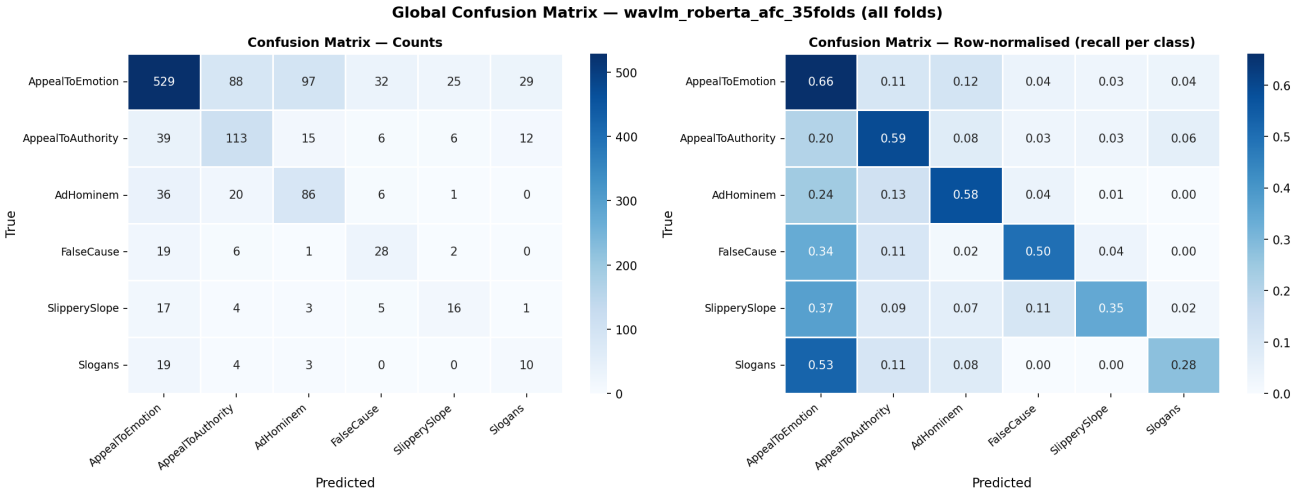

FIGURE 9 – Matrice de confusion agrégée sur 35 folds WavLM + RoBERTa (AFC). Appeal to Emotion reproduit le même pattern attracteur qu'en texte seul.

Analyse différentielle des erreurs. La Figure 10 détaille l'impact de MM par rapport au texte seul : MM dégrade 491 snippets correctement classifiés par le texte, contre seulement 153 corrections un bilan négatif. Le pattern principal révèle un biais prosodique : quand MM se trompe sur Ad Hominem (279/800 snippets cassés, 35%), il la confond avec Appeal to Authority (106 fois) et Appeal to Emotion (98 fois). L'audio pousse le modèle vers les classes à signature prosodique marquée ton d'autorité, émotion dans la voix au détriment d'Ad Hominem, qui est une attaque personnelle souvent neutre prosodiquement.

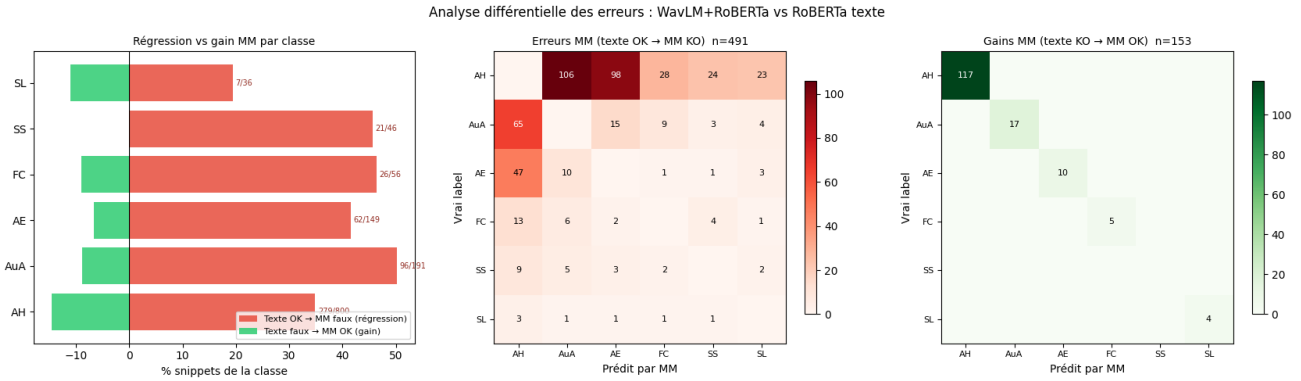

FIGURE 10 – Analyse différentielle des erreurs : WavLM+RoBERTa vs RoBERTa texte. **Gauche** : régression vs gain MM par classe. **Centre** : erreurs MM (texte OK → MM KO, $n = 491$). **Droite** : gains MM (texte KO → MM OK, $n = 153$).

4.1.3 Extension — Contexte dialogique ciblé (N-1)

Les expériences exploratoires sur 5 folds ont montré qu'un contexte dialogique complet dégrade les performances (F1 = 0,352), quelle que soit l'architecture utilisée. Le test technique identifie également le contexte ciblé ($N - 1$, $N - 2$ tours) comme piste d'amélioration prometteuse pour la Partie C. Nous avons donc implémenté et validé cette hypothèse sur les 35 folds complets via `ContextMMUSEDFallacy(k=1)`, limitant le contexte au seul tour précédent.

Résultat. WavLM + RoBERTa avec contexte $k = 1$ obtient un macro F1 de 0,426 (± 0,190) sur 35 folds en dessous de la baseline multimodale sans contexte (0,445) et du texte seul (0,476). L'ajout d'un seul tour de contexte ne récupère pas le signal perdu.

Interprétation. Même un contexte minimal dégrade les performances. Ce résultat confirme que le problème n'est pas la quantité de contexte mais sa nature : toute phrase non-fallacieuse ajoutée au snippet cible amplifie le biais vers la classe majoritaire, indépendamment de la proximité dialogique. Quand le texte seul est déjà discriminant, le contexte n'apporte rien et quand le texte est faible, le contexte ne contient pas forcément de signature discriminante pour la fallacy ciblée.

4.1.4 Comparaison des trois modèles

Résultats globaux. Sur les 35 folds LODO complets, RoBERTa texte reste le meilleur modèle (F1 = 0,476). WavLM+RoBERTa perd 3,1 points (F1 = 0,445), et la variante $k = 1$ perd encore 1,8 points supplémentaires (F1 = 0,426). Le prédicteur principal du gain multimodal est la force du signal textuel ($r = -0{,}642$, $p < 0{,}001$) : l'audio dégrade là où le texte suffit et n'apporte qu'un gain limité là où il est faible. Le contexte $k = 1$ n'inverse pas cette tendance il l'aggrave marginalement.

F1 par classe. La Figure 11 compare le F1 par classe des trois modèles. Le pattern n'est pas uniforme chaque modalité présente des avantages sur des classes spécifiques.

Le texte seul domine sur Appeal to Emotion (0,55 vs 0,53 pour MM et MM $k = 1$) et False Cause (0,43 vs 0,43 et 0,36). En revanche, MM $k = 1$ apporte un gain ciblé sur Ad Hominem (0,50 vs 0,49 pour le texte et MM) et récupère du signal sur Slippery Slope (0,39 vs 0,33 pour MM sans contexte), suggérant que le tour précédent apporte un contexte argumentatif utile pour ces classes à structure logique complexe. Appeal to Authority reste comparable entre les trois modèles (0,75 / 0,72 / 0,74).

Slippery Slope illustre la limite de la fusion naïve : MM sans contexte dégrade fortement (F1 = 0,33 vs 0,42 pour le texte) car cette fallacy purement argumentative n'a pas de signature acoustique l'audio introduit du bruit sans signal complémentaire. MM $k = 1$ récupère partiellement ce signal (0,39), confirmant que le contexte dialogique apporte une information utile pour les fallacies à structure logique étendue sur plusieurs tours.

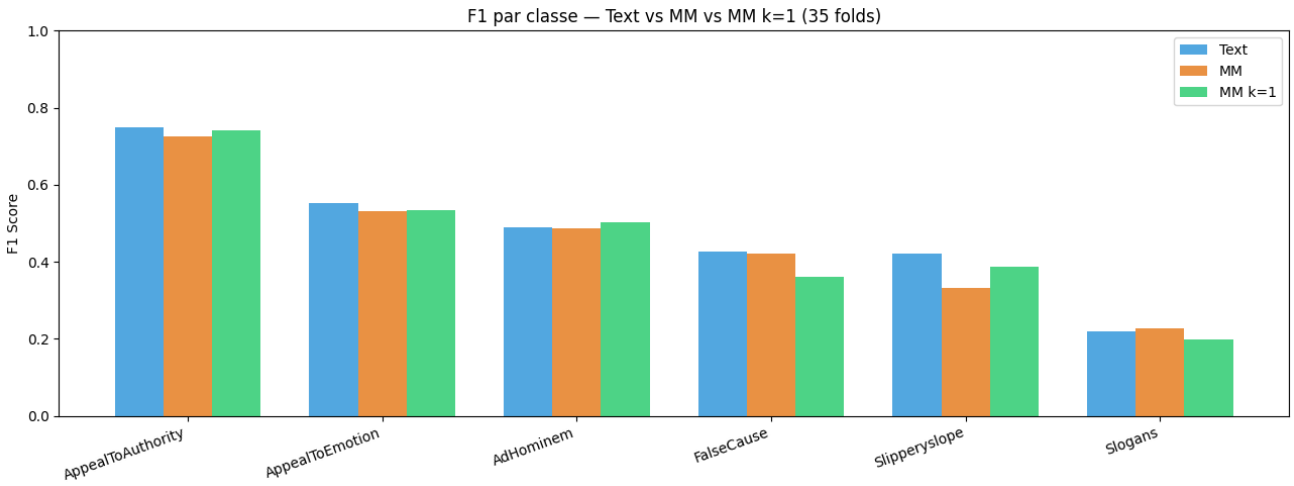

FIGURE 11 – F1 par classe Text vs MM vs MM $k = 1$ (35 folds LODO). Le texte seul domine sur la majorité des classes. Slippery Slope est la classe la plus dégradée par la fusion audio.

Tests statistiques. Le forest plot (Figure 12) confirme l'absence de différence significative entre les trois modèles sur 35 folds :

- MM vs Text : $p = 0{,}565$, $\Delta\text{F1} = -0{,}032$, IC 95% $= [-0{,}110,\ +0{,}045]$ 16/35 wins MM.
- MM $k = 1$ vs Text : $p = 0{,}280$, $\Delta\text{F1} = -0{,}050$, IC 95% $= [-0{,}126,\ +0{,}025]$ 13/35 wins MM $k = 1$.
- MM $k = 1$ vs MM : $p = 0{,}367$, $\Delta\text{F1} = -0{,}018$, IC 95% $= [-0{,}058,\ +0{,}022]$ 15/35 wins MM $k = 1$.

Aucune comparaison n'atteint $p < 0{,}05$. Sur 35 folds LODO, ni l'audio ni le contexte dialogique ciblé n'améliorent de façon robuste la détection des sophismes par rapport au texte seul.

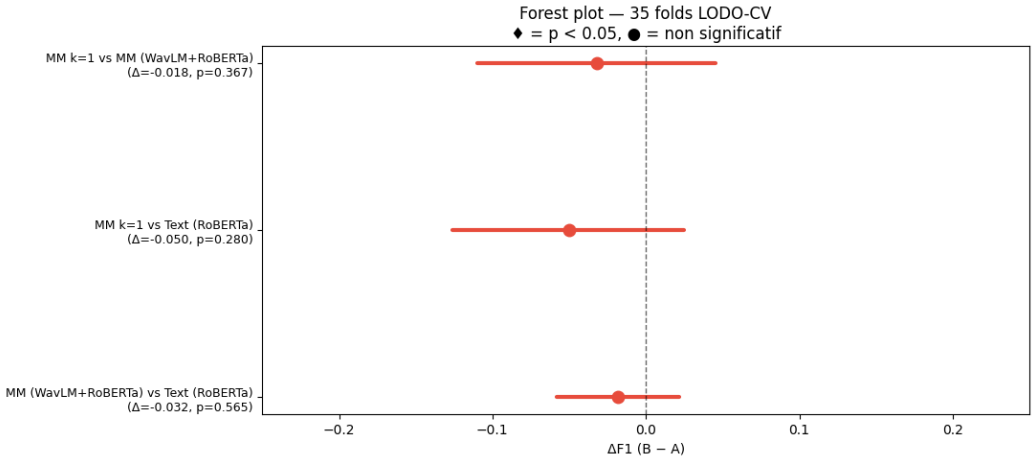

FIGURE 12 – Forest plot des différences de F1 avec IC bootstrap 95% (35 folds LODO-CV). Tous les IC contiennent 0 aucune comparaison n'est statistiquement significative.

L'ensemble des résultats AFC sur 35 folds converge vers une conclusion unifiée : RoBERTa texte seul reste le modèle le plus robuste (F1 = 0,476), la fusion multimodale n'apportant aucun gain statistiquement significatif ($p = 0{,}565$). L'analyse XAI révèle que ce résultat s'explique par un shortcut learning sur les mots fonctionnels et un biais d'attraction vers Appeal to Emotion biais que l'audio amplifie plutôt que corrige, en introduisant une pression prosodique supplémentaire vers les classes à signature acoustique marquée. Le contexte $k = 1$ atténue localement ce biais sur Ad Hominem et Slippery Slope mais ne le résout pas globalement ($p = 0{,}280$). Ces résultats indiquent que la complémentarité entre modalités existe mais reste inexploitable par une architecture de fusion naïve, motivant des approches plus sophistiquées comme la cross-attention token-frame guidée par les timestamps Whisper.

4.2 Argumentative Fallacy Detection (AFD)

L'AFD est une classification binaire fallacieux ou non-fallacieux sur l'ensemble des phrases du corpus, avec un déséquilibre sévère (90,8% non-fallacieux).

4.2.1 Baseline texte

RoBERTa obtient un binary F1 de 0,308 (± 0,133) sur 35 folds. La tâche est structurellement plus difficile que l'AFC : le modèle doit distinguer une phrase fallacieuse parmi 90,8% de phrases non-fallacieuses.

L'examen des erreurs confirme cette difficulté. Un snippet prédit *non-fallacieux* alors qu'il contient un Slogan :

> *"We have to be tough on crime."* (vrai label : Fallacieux Slogan)

La brièveté et la formulation assertive, sans marqueur émotionnel explicite, poussent le modèle à prédire *non-fallacieux* par défaut se rabattant sur la classe majoritaire.

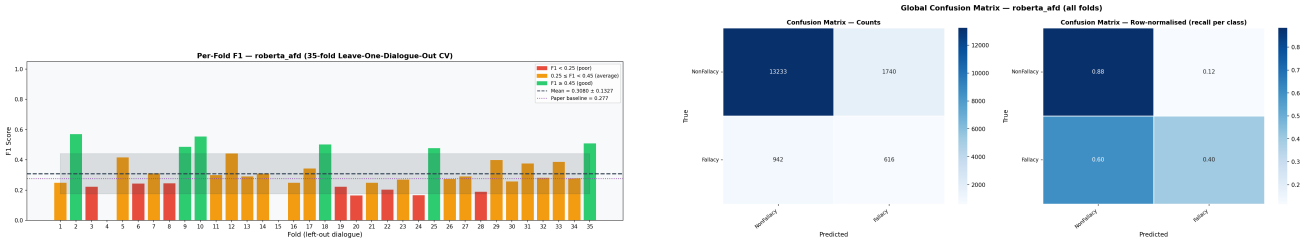

FIGURE 13 – **Gauche** : binary F1 AFD par fold (35 folds LODO). **Droite** : matrice de confusion AFD le modèle prédit majoritairement non-fallacieux.

La Figure 13 révèle une variance inter-folds notable (F1 entre 0 et 0,57), mais structurellement différente de l'AFC : l'absence de pics mécaniques à F1 = 1,0 reflète la nature binaire de la tâche, où même un dialogue simple contient des phrases non-fallacieuses qui peuvent piéger le modèle. Le fold 4 obtient F1 = 0 le modèle ne détecte aucune fallacy, se rabattant entièrement sur la classe majoritaire. À l'inverse, les folds 2 et 10 (F1 ≈ 0,57) correspondent à des dialogues où les fallacies présentent des marqueurs lexicaux suffisamment discriminants pour émerger malgré le déséquilibre. La baseline du papier (0,277) est dépassée sur la majorité des folds, confirmant la cohérence de notre reproduction sur un protocole alternatif.

4.2.2 Baseline multimodale

La baseline multimodale sur les 5 folds audio obtient 0,319 (± 0,084), inférieure au texte seul (0,354 ± 0,120) sur ces mêmes folds. Ce résultat contraste avec le léger gain multimodal observé dans le papier (0,2848 vs 0,2770), divergence attribuable à la différence de dataset et au faible nombre de folds évalués rendant cette comparaison statistiquement fragile. La détection binaire reste quasi-exclusivement portée par le signal textuel : distinguer une phrase fallacieuse parmi 90,8% de phrases non-fallacieuses repose sur des indices sémantiques fins que l'audio seul ne suffit pas à compenser sur ce sous-ensemble de dialogues.

4.3 Synthèse comparative

Le tableau 1 présente l'ensemble des résultats obtenus sur les deux tâches.

Modèle	**Tâche**	**Folds**	**F1 moyen**	**Std**
Baselines texte				
RoBERTa texte	AFC	35	0,476	0,180
RoBERTa texte	AFD	35	0,308	0,133
Baselines multimodales				
WavLM + RoBERTa	AFC	35	0,445	0,183
WavLM + RoBERTa	AFD	5*	0,319	0,084
Extension contexte ciblé				
WavLM + RoBERTa $k = 1$	AFC	35	0,426	0,190
Baselines du papier (indicatif)				
Baseline Transformer	AFC	–	*0,393*	–
Baseline Transformer	AFD	–	*0,277*	–
MM(Baseline)	AFC	–	*0,3816*	–
MM(Basline)	AFD	–	*0,2848*	–

TABLE 1 – Résultats de toutes les expériences conduites. Macro F1 pour l'AFC, binary F1 pour l'AFD. *L'AFD multimodal est évalué sur 5 folds uniquement en raison de contraintes computationnelles. Les baselines du papier sont évaluées sur un secret test set non public et reportées à titre indicatif uniquement.

Plusieurs patterns émergent de cette vue d'ensemble.

Premièrement, la modalité textuelle domine systématiquement sur les deux tâches : RoBERTa texte seul obtient les meilleures performances stables (AFC : 0,476 ; AFD : 0,308). L'analyse XAI explique cette dominance par un shortcut learning sur les mots fonctionnels et un biais d'attraction vers Appeal to Emotion phénomène cohérent avec l'IAA modéré du papier (kappa = 0,411). À titre indicatif, ces scores dépassent les baselines Transformer du papier (0,393 AFC ; 0,277 AFD), bien que les protocoles d'évaluation soient différents et ne permettent pas de comparaison directe.

Deuxièmement, la fusion multimodale ne démontre aucun gain statistiquement significatif sur l'AFC ($p = 0{,}565$, $\Delta\text{F1} = -0{,}032$). L'analyse différentielle des erreurs révèle que l'audio introduit un biais prosodique systématique poussant le modèle vers les classes à signature acoustique marquée (Appeal to Emotion, Appeal to Authority) au détriment des classes à structure logique (Ad Hominem, Slippery Slope). Ce biais est d'autant plus fort que le texte est déjà discriminant ($r = -0{,}642$, $p < 0{,}001$). Sur l'AFD, la fusion multimodale reste également inférieure au texte seul sur les 5 folds évalués (0,319 vs 0,354).

Troisièmement, le contexte dialogique ciblé ($k = 1$) ne résout pas le problème de redondance entre modalités ($p = 0{,}280$, $\Delta\text{F1} = -0{,}050$ vs texte). La comparaison par classe montre néanmoins des gains locaux sur Ad Hominem et Slippery Slope, suggérant que le contexte apporte un signal utile pour les fallacies à structure logique complexe, mais insuffisant pour compenser la dégradation sur les autres classes.

Ces résultats convergent vers une conclusion unifiée : sur ce corpus et avec ces architectures, la complémentarité entre modalités texte et audio reste inexploitable par une fusion late naïve, indépendamment de l'ajout de contexte dialogique. Des approches plus sophistiquées cross-attention token-frame guidée par les timestamps Whisper, apprentissage multi-tâches constituent les perspectives naturelles de ce travail.

5 Discussion, Perspectives et Conclusion

Les résultats confirment la dominance textuelle, mais révèlent que celle-ci découle moins d'une supériorité intrinsèque du texte que d'une incapacité des architectures actuelles à résoudre le conflit d'information entre les modalités. L'analyse différentielle montre un biais prosodique ($r = -0{,}642$, $p < 0{,}001$) : l'audio, mal intégré, agit comme un distracteur qui pousse le modèle vers des classes à signature acoustique marquée, au détriment de la structure logique. L'analyse XAI confirme ce shortcut learning : le modèle s'appuie sur des pivots lexicaux superficiels dès que la complexité argumentative augmente. Le contexte ciblé $k = 1$, bien que non significatif globalement ($p = 0{,}280$), apporte des gains locaux sur Ad Hominem et Slippery Slope confirmant que le signal contextuel existe mais que la concaténation naïve ne permet pas de l'exploiter. Ce gain ciblé suggère que Ad Hominem et Slippery Slope bénéficient davantage du contexte dialogique que les autres classes, probablement en raison de leur structure logique plus complexe qui s'étend au-delà du snippet isolé. Cette observation ouvre une piste de recherche : un contexte sélectif guidé par des marqueurs argumentatifs plutôt que systématique pourrait amplifier ce bénéfice sans introduire de bruit sémantique.

Pour dépasser ces limites dans le cadre d'un projet de thèse, trois axes de recherche structurants sont proposés.

Mécanismes de fusion guidés par l'attention. Plutôt qu'une simple concaténation, une cross-attention token-frame alignée via les timestamps Whisper permettrait de traiter l'audio non plus comme un signal global, mais comme un modulateur sémantique. L'objectif est de forcer le modèle à vérifier si une emphase acoustique valide ou contredit un pivot lexical détecté brisant ainsi le shortcut learning en n'activant certaines prédictions que si les indices textuels et paralinguistiques convergent vers une intention rhétorique commune.

Apprentissage multi-tâches pour la robustesse logique. Pour réduire la dépendance aux biais lexicaux, un apprentissage multi-tâches couplant l'AFC avec l'extraction de composants argumentatifs (MM-USED, M-Arg) est crucial. En forçant l'encodeur à identifier d'abord la structure de l'argument, le modèle serait contraint d'apprendre des représentations structurelles plutôt que de simples corrélations de mots, rendant la détection des sophismes dépendante de la logique et non plus de la syntaxe superficielle.

Modélisation de l'identité rhétorique (speaker-aware). L'analyse fold par fold a montré que le style prosodique des locuteurs parasite le signal audio. En apprenant des embeddings de locuteurs, le modèle pourrait distinguer une signature vocale habituelle d'une variation prosodique liée spécifiquement à une stratégie de manipulation permettant d'exploiter le signal audio indépendamment du style rhétorique propre à chaque politicien.

La principale limite de ce travail est l'utilisation de MAMKit 0.1.1 [Mancini et al., 2024a] plutôt que la version WhisperX [Bain et al., 2023], réduisant le dataset de 3 388 à 1 278 instances AFC. Une limite supplémentaire concerne l'asymétrie des espaces de représentation : le vecteur textuel (768d) est trois fois plus grand que le vecteur audio (256d), favorisant la domination du signal textuel dans la concaténation finale. Ces résultats convergent vers

une conclusion unifiée : le véritable verrou n'est pas d'améliorer le score F1, mais de concevoir des architectures capables de modéliser l'interaction dynamique entre l'intention paralinguistique et la structure logique ouvrant la voie à une IA capable de comprendre la rhétorique au-delà des mots.

Références

Max Bain, Jaesung Huh, Tengda Han, and Andrew Zisserman. WhisperX : Time-accurate speech transcription of long-form audio. In *Interspeech 2023*, pages 4489–4493, 2023.

Sanyuan Chen, Chengyi Wang, Zhengyang Chen, Yu Wu, Shujie Liu, et al. WavLM : Large-scale self-supervised pre-training for full stack speech processing. *IEEE Journal of Selected Topics in Signal Processing*, 16(6) : 1505–1518, 2022.

Pierpaolo Goffredo, Shohreh Haddadan, Vorakit Vorakitphan, Elena Cabrio, and Serena Villata. Fallacious argument classification in political debates. In *Proceedings of the Thirty-First International Joint Conference on Artificial Intelligence*, 2022.

Shohreh Haddadan, Elena Cabrio, and Serena Villata. Yes, We Can ! Mining arguments in 50 years of US presidential campaign debates. In *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*, 2019.

Gabrijela Kišiček. Listen carefully ! Fallacious auditory arguments. In *Proceedings of the 12th Conference of the Ontario Society for the Study of Argumentation*, 2020.

Tsung-Yi Lin, Priya Goyal, Ross Girshick, Kaiming He, and Piotr Dollár. Focal loss for dense object detection. In *2017 IEEE International Conference on Computer Vision (ICCV)*, 2017.

Marco Lippi and Paolo Torroni. Argument mining from speech : Detecting claims in political debates. In *Proceedings of the Thirtieth AAAI Conference on Artificial Intelligence*, 2016.

Yinhan Liu, Myle Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer, and Veselin Stoyanov. RoBERTa : A robustly optimized BERT pretraining approach. *arXiv preprint arXiv :1907.11692*, 2019.

Eleonora Mancini, Federico Ruggeri, Andrea Galassi, and Paolo Torroni. Multimodal argument mining : A case study in political debates. In *Proceedings of the 9th Workshop on Argument Mining*, 2022.

Eleonora Mancini, Federico Ruggeri, Stefano Colamonaco, Andrea Zecca, Samuele Marro, and Paolo Torroni. MAMKit : A comprehensive multimodal argument mining toolkit. In *Proceedings of the 11th Workshop on Argument Mining*, 2024a.

Eleonora Mancini, Federico Ruggeri, and Paolo Torroni. Multimodal fallacy classification in political debates. In *Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics*, 2024b.

Eleonora Mancini, Federico Ruggeri, Serena Villata, and Paolo Torroni. Overview of MM-ArgFallacy2025 on multimodal argumentative fallacy detection and classification in political debates. In *Proceedings of the 12th Workshop on Argument Mining*, 2025.

Rafael Mestre, Stuart E. Middleton, Matt Ryan, Masood Gheasi, Timothy Norman, and Jiatong Zhu. Augmenting pre-trained language models with audio feature embedding for argumentation mining in political debates. In *Findings of the Association for Computational Linguistics : EACL 2023*, 2023.

Alessio Pittiglio. Leveraging context for multimodal fallacy classification in political debates. In *Proceedings of the 12th Workshop on Argument Mining*, 2025.

Alec Radford, Jong Wook Kim, Tao Xu, Greg Brockman, Christine McLeavey, and Ilya Sutskever. Robust speech recognition via large-scale weak supervision. In *Proceedings of the 40th International Conference on Machine Learning*, pages 28492–28518, 2023.

Annexe — Expériences exploratoires sur 5 folds

Toutes les expériences de cette annexe ont été conduites sur les 5 folds disposant de clips audio alignés (`13_1988, 22_1996, 25_2000, 31_2004, 46_2020`), soit environ 14% du corpus total. Ces résultats sont indicatifs et non généralisables ils ont servi à orienter le choix de l'extension principale (contexte ciblé $k = 1$, Section 4.1.3).

Rôle de Whisper dans nos analyses. Whisper [Radford et al., 2023] a été utilisé à deux fins distinctes dans ce travail. Premièrement, comme outil d'audit qualité (Section 3.1) : la transcription automatique des clips audio a permis de calculer le WER et de classifier les clips en quatre catégories (Good, BadAlignment, TooShort, TooLong), révélant que 51,6% des clips sont bien alignés et que le misalignment est principalement fonctionnel. Deuxièmement, comme texte d'entrée alternatif dans l'expérience §3 ci-dessous, pour tester si remplacer le texte annoté par la transcription automatique améliore la fusion multimodale.

Résultats comparatifs. Les résultats détaillés par configuration sont présentés ci-dessous.

Configuration	**F1 moyen (5 folds)**	**Std**
WavLM + RoBERTa (référence)	0,502	0,057
Audio découpé (Trimmed)	0,399	0,094
Transcription Whisper comme texte	0,362	0,127
Contexte dialogique complet	0,352	0,104
Longformer + contexte complet	0,379	0,075

Table 2 – Résultats des expériences exploratoires sur 5 folds AFC. Toutes les configurations dégradent la référence multimodale.

Audio découpé (Trimmed). Découper les clips aux timestamps exacts des mots du snippet (F1 = 0,399, −10,3 pts) confirme que le contexte acoustique voisin porte une information paralinguistique utile. Ce résultat valide la conclusion de l'audit Whisper (Section 3.1) : le misalignment de MAMKit 0.1.1 est fonctionnel, pas du bruit.

Transcription Whisper comme texte. Remplacer le texte annoté par la transcription automatique Whisper (F1 = 0,362, −14,0 pts) confirme que RoBERTa performe mieux avec le texte annoté précis. La transcription inclut le speech voisin, introduisant du bruit textuel. Cette expérience établit que l'alignement exact audio-texte n'améliore pas la fusion la redondance entre modalités est le facteur limitant, pas leur désalignement.

Contexte dialogique complet et Longformer. Le contexte complet (F1 = 0,352) et Longformer (F1 = 0,379) dégradent tous deux les performances. L'analyse de la longueur des tokens confirme que les séquences restent sous 200 tokens même avec le contexte complet excluant une explication par la troncation. La dégradation est due au bruit sémantique du contexte, indépendamment du mécanisme d'attention. Ces observations ont motivé le choix du contexte ciblé $k = 1$.