Détection Multimodale de Sophismes dans les Débats Politiques

Reproduction et Extension Méthodologique de MM-ArgFallacy2025

Boutheina Chebouti | Test Technique — Alten / EFREI | Avril 2026

Plan de la présentation:

01 Contexte & Motivation

02 Pipeline expérimental

03 Résultats & Analyse

04 Proposition méthodologique & Perspectives

De l'Argument Mining à la Détection Multimodale de Sophismes

1. Les débats politiques constituent un terrain privilégié de manipulation rhétorique.
2. Le texte seul ne suffit pas : l'intonation et les signaux audio révèlent ce que les mots dissimulent.
3. Détecter ces sophismes automatiquement représente un enjeu démocratique majeur.
4. Tâche ambiguë même pour des experts humains — accord inter-annotateurs faible ($\kappa \approx 0.48$).

MM-ArgFallacy2025 : La Shared Task

01

2 Modalités testées

Texte seul
Texte + Audio (prosodique)

02

2 Sous-tâches

AFD — Détection binaire (fallacy / no fallacy)
AFC — Classification en 6 catégories de sophismes

03

Toolkit

MAMKit 0.1.1 · 35 dialogues (1960–2016)
1 278 instances AFC · 17 118 instances AFD

04

Écart avec le papier

MAMKit 0.1.1 sans WhisperX :
Nombre d'instance
Secret set non valable

Pipeline & Setup Expérimental

01. Dataset et Preparation des données

- **Distributions des classes**

AFC : Appeal to Emotion domine à 62,6%
risque de biais d'attraction

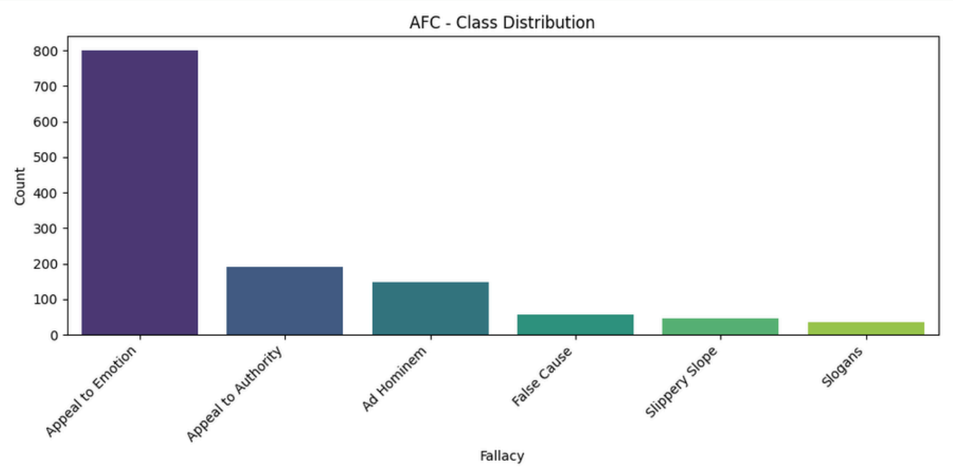

AFD : 90,8% non-fallacieux
un modèle naïf atteindrait 90,8% d'accuracy
sans rien apprendre

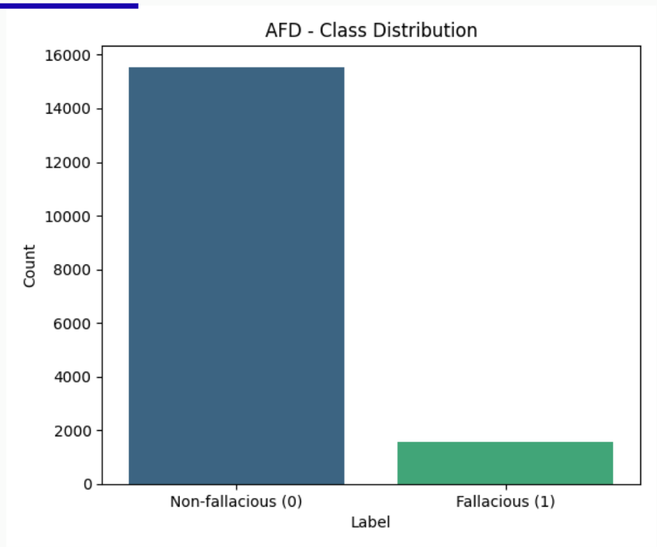

Pipeline & Setup Expérimental

01. Dataset et Preparation des données

- **Déséquilibre inter-dialogues**

- **Taux de fallacies par dialogue : 2,8% à 18,1% (moyenne 9,5%)**
- **Hétérogénéité structurelle du corpus → variance inter-folds**

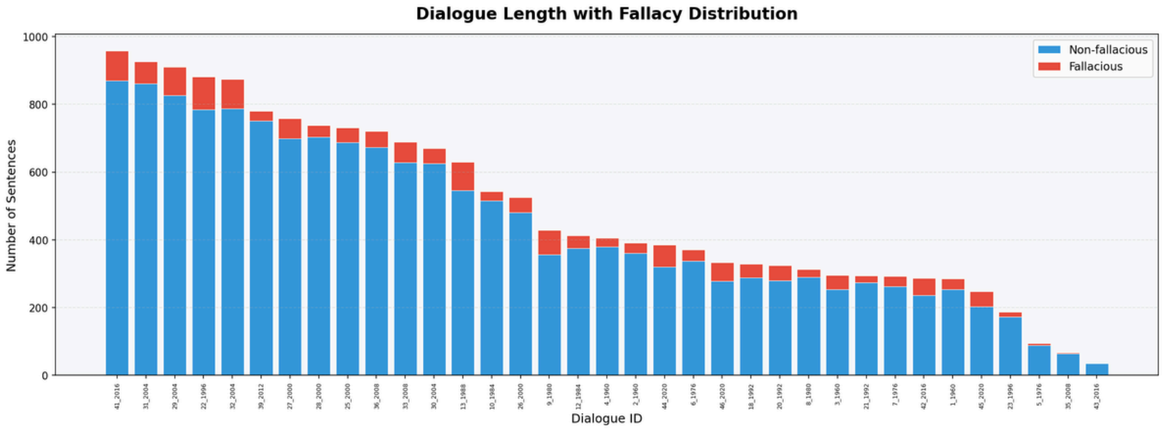

- **Audit Qualité Audio**

- **Whisper + overlap textuel + similarité sémantique**
- **51,6% bien alignés misalignment fonctionnel, pas du bruit**

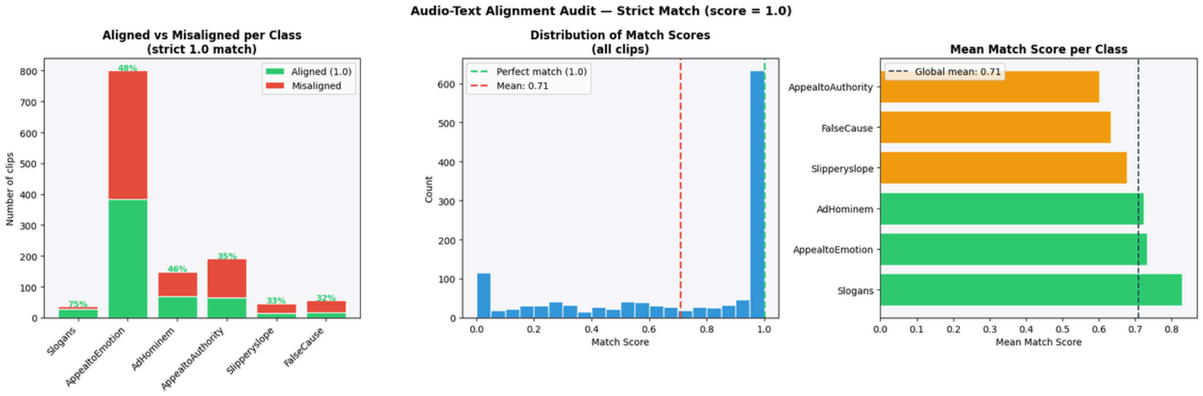

Exemple 1 — Troncature partielle
REF : "He just doesn't understand how the borders work, evidently, to say that. That is an outrageous claim."
WHISPER : "He just doesn't understand how the borders work evidently." WER = 0.47 | match = 0.53
Exemple 2 — Désalignement sévère
REF : "Prime Minister Rabin gave his life because someone in his own country literally hated him for trying to bring peace. I would like to have had a big, organized summit..."
WHISPER : "Prime Minister Rabin gave his life because someone in his own country literally hated him for trying to bring peace." WER = 0.57 | match = 0.43

Modèles & Architecture

01. AFD et AFC

Baseline texte — RoBERTa

- RoBERTa-base → masked mean-pooling (768d) → classification linéaire

02. AFD et AFC

Baseline multimodale — WavLM + RoBERTa

- WavLM-base → BiLSTM (256d) + RoBERTa (768d) → concaténation (1024d) → classification

03. AFC

Extension — Contexte dialogique k=1

- ContextMMUSEDFallacy(k=1) : tour précédent concaténé au snippet cible avant tokenisation

04. AFC

Expériences exploratoires (5 folds)

- Audio découpé :
- Whisper comme texte
- Contexte complet
- Longformer + contexte complet
- Focal loss

Protocole d'Évaluation & Gestion du Déséquilibre

01. Protocole LODO-CV :

- RoBELeave-One-Dialogue-Out sur 35 folds
- Baselines principales : 35 folds complets
- Exploratoires : 5 folds audio

02. Gestion du déséquilibre

- Weighted cross-entropy
  AFC : [0.27 → 5.92]
  AFD : [0.55, 5.46]
- Focal loss testée

03. Métriques

- Macro F1 pour AFC : traite équitablement toutes les classes
- Binary F1 pour AFD : évite l'accuracy trompeuse (90,8% non-fallacieux)

04. Hyperparamètres

- Adam, lr=10^{-5}, weight decay=10^{-5}
- batch=8 , 20 epochs max
- Early stopping (patience=5), dropout=0.1
- seed=42 réinitialisée à chaque fold

Resultats

01. Resultats AFC

a. Baseline text - Roberta

Macro F1 = 0,476 (± 0,180) sur 35 folds LODO Dépasse la baseline du papier (0,393) (protocoles différents)

Analyse par classe

Appeal to Emotion : meilleur recall (0,71) — attracteur dominant
Slogan (0,21) et False Cause (0,18) : très difficiles
Snippets courts → F1 faibles (Slogan médiane ≈ 15 mots)

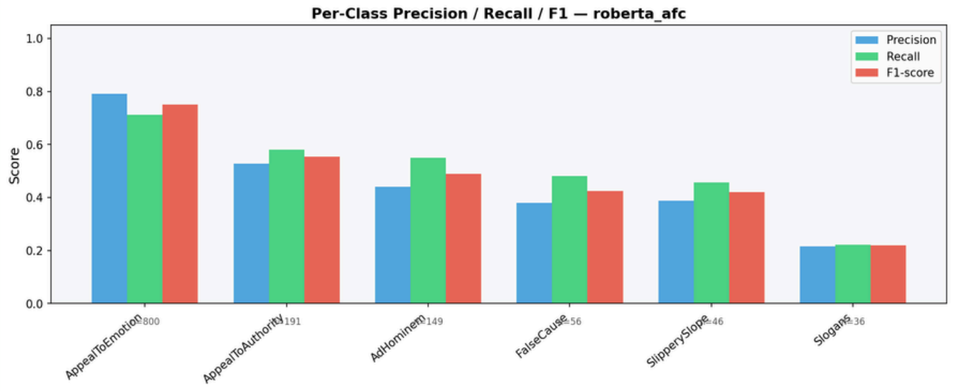

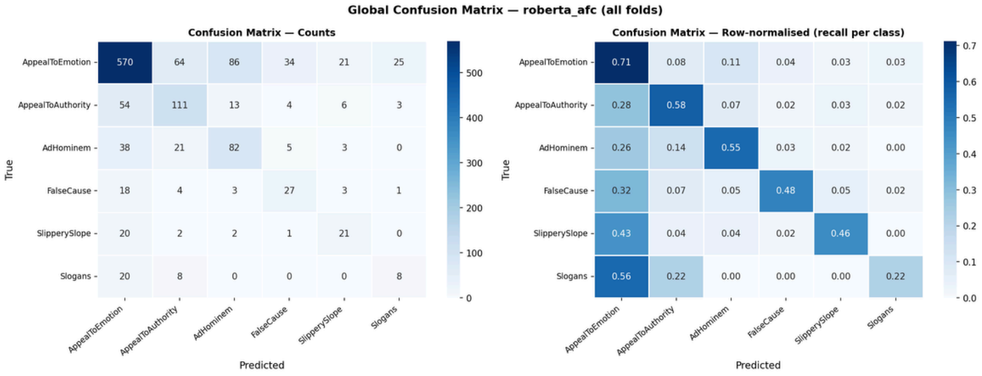

Variance inter-folds

Forte variance → propriété du dataset, pas instabilité du modèle Folds à 1 seule classe → F1 = 1,0 mécaniquement
Folds avec 5-6 classes mais peu d'exemples → F1 ≈ 0

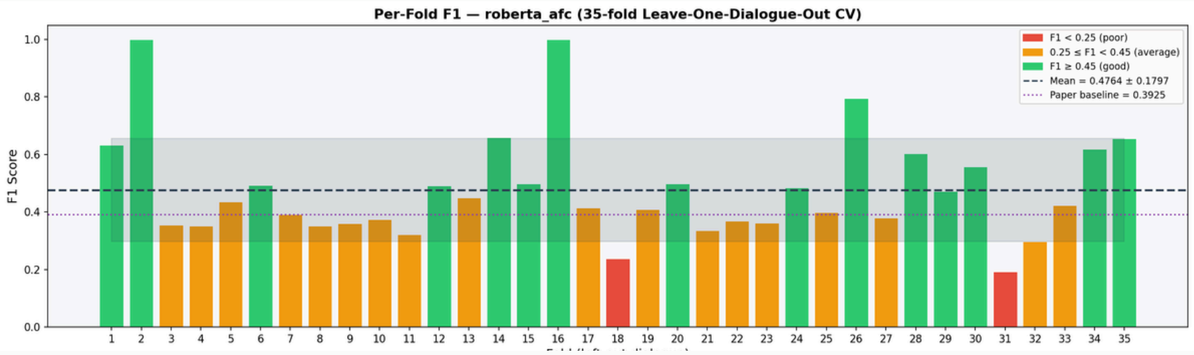

Exemples d'erreurs

prédit *Appeal to Emotion* , ***vrai label*** *: False Cause*
"It would, of course, be a very serious situation..."
prédit *Appeal to Emotion* , ***vrai label*** *: Ad Hominem*
...is, in my opinion, a total non-STARTer."

Resultats

01. Resultats AFC

Analyse XIA

- 3 méthodes combinées : Attention du dernier layer + Gradient saliency + SHAP (partition explainer)

SHAP

Gradient saliency

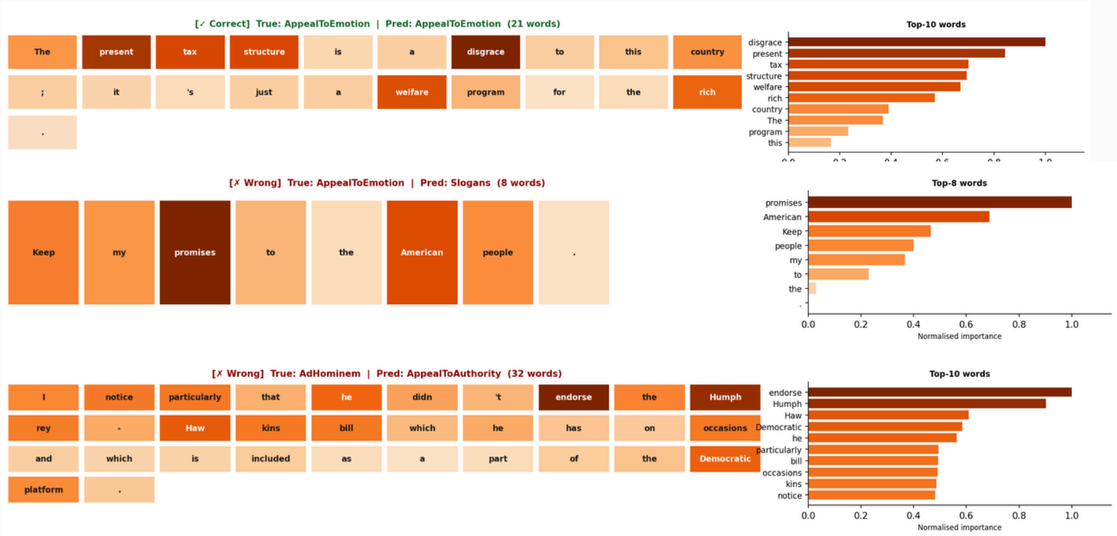

- Quand une classe est bien représentée , il apprend ses vrais tokens discriminants.
- Quand une classe est rare , il prédit Appeal to Emotion par défaut, sans même activer les tokens discriminants de cette classe.
- Ce n'est pas juste du shortcut learning , c'est un effondrement vers la classe majoritaire sur les folds difficiles.
- Le modèle ne "voit" littéralement pas False Cause ou Slogan, il les absorbe dans Appeal to Emotion
- “Keep my promises to the American people" → prédit Slogan , vrai label Appeal to Emotion
  ambiguïté intrinsèque entre catégories, cohérente avec Kappa ≈ 0.48

Resultats

01. Resultats AFC

b. WavLM+RoBERTa

- Macro F1 = 0,445 (± 0,183) sur 35 folds LODO En dessous du texte seul (0,476) → dominance textuelle confirmée
- les score est en dessous de la baseline du papier (F1=0.46)
- Le MM suit le meme pattern que RoBERTa pour la performance par classe (Appeal to emotion attracteur majeur)

Analyses cles :

- **Texte faible : MM apporte un gain modeste**
- **Texte moyen : MM neutre**
- **Texte fort : MM dégrade fortement (Δ moyen = −0,316)**
- **Absence de corrélation entre qualité audio et F1 multimodal**
- **Biais prosodique : MM dégrade 491 snippets correctement classifiés par le texte, corrige seulement 153**

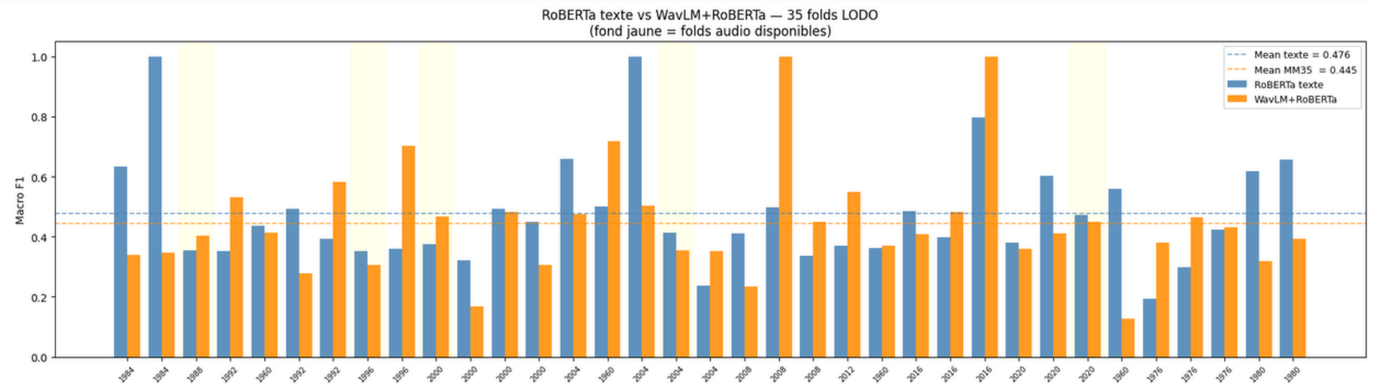

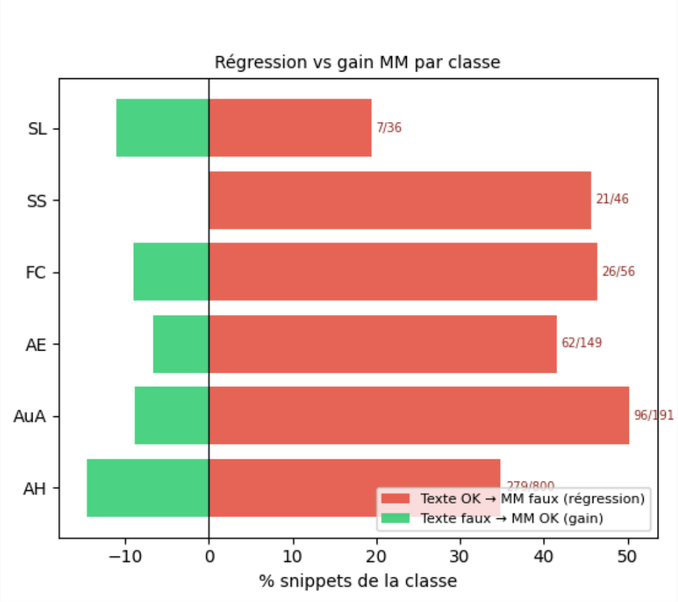

Pour toutes les classes, la barre rouge dépasse largement la barre verte → MM dégrade plus qu'il n'améliore, et c'est Slippery Slope qui souffre le plus car c'est souvent neutre prosodiquement l'audio n'apporte rien.

Resultats

01. Resultats AFC

c. Extension-Context Dialogue cible (N-1)

- Macro F1 = 0,426 (± 0,190) sur 35 folds
- En dessous de MM (0,445) et texte seul (0,476)

Analyse par classe :

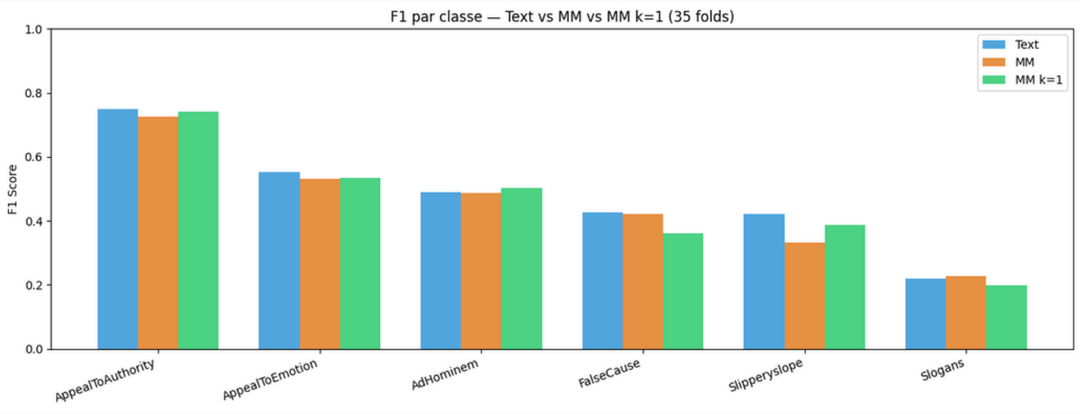

d. Tests statistiques (Forest plot):

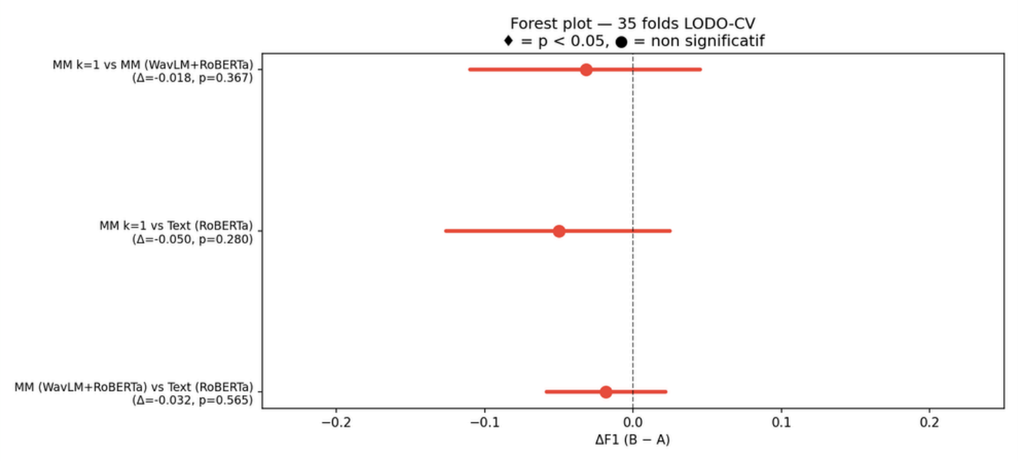

MM vs Text : p = 0,565 → non significatif
MM k=1 vs Text : p = 0,280 → non significatif
MM k=1 vs MM : p = 0,367 → non significatif
Aucune comparaison n'atteint p < 0,05

Resultats

e . Synthese comparatif AFC

- Toute phrase non-fallacieuse ajoutée amplifie le biais vers la classe majoritaire

Modele	Tache (AFC)
RoBERTa texte	0,308 (0.133)
WavLM + RoBERTa	0,319 (0.08)
WavLM + RoBERTa k=1	0,277
Baseline Multimodale du papier	0.2848
Baseline text du papier	0.2770

Axes d'exploration & enseignements :

- Audio découpé (−10,3 pts) → le contexte acoustique voisin porte un signal paralinguistique utile
- Whisper comme texte (−14,0 pts) → la redondance entre modalités est le facteur limitant, pas le désalignement
- Contexte complet (−12,4 pts) → le bruit sémantique dégrade, indépendamment de la longueur des séquences
- Longformer (−12,3 pts) → le problème n'est pas la fenêtre d'attention mais la nature du contexte
- Focal loss (−28,8 pts) → la weighted cross-entropy est mieux adaptée au double déséquilibre

Resultats

02. Resultats AFD

Résultats AFD — Comparaison avec le Papier

	AFD
TEXT (RoBERTa)	0,308 (0.133)
Multimodale (WavLm+ RoBERTa)	0,319 (0.08)
Baseline text du papier	0,277
Baseline Multimodale du papier	0.2848

Analyses cles :

- tâche structurellement plus difficile que l'AFC
- Le modèle prédit majoritairement non-fallacieux → se rabat sur la classe majoritaire (90,8%)
- AFD quasi-exclusivement portée par le signal textuel
- Distinguer fallacieux / non-fallacieux repose sur des indices sémantiques et syntaxiques fins

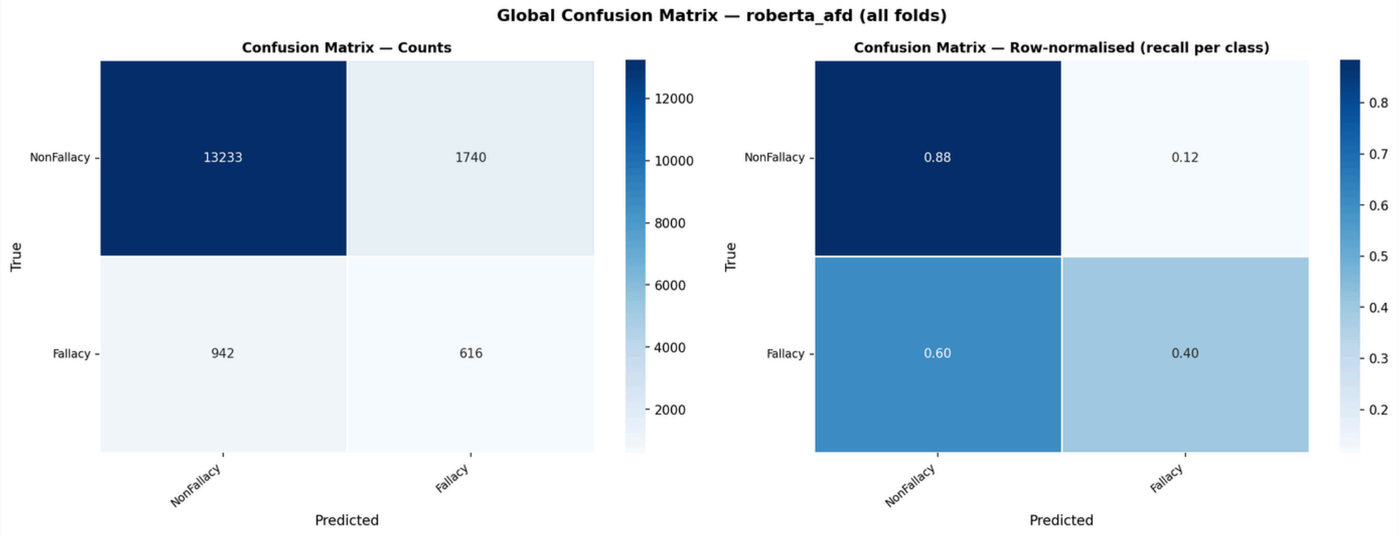

Discussion, Limites & Perspectives

Discussion

- Dominance textuelle ≠ supériorité intrinsèque → incapacité architecturale à résoudre le conflit d'information
- Audio mal intégré = distracteur prosodique (r = −0,642)
- Contexte k=1 : signal utile pour Ad Hominem & Slippery Slope mais concaténation naïve insuffisante
- Piste : contexte sélectif guidé par marqueurs argumentatifs

Limites

- MAMKit 0.1.1 sans WhisperX → 1 278 vs 3 388 instances AFC
- Asymétrie 768d / 256d → domination du signal textuel dans la concaténation finale

Axes d'Amélioration

Cross-attention token-frame

Guidée par Whisper → audio comme modulateur sémantique, non distracteur

Multi-tâches AFC + extraction argumentative

Structure logique vs corrélations lexicales superficielles (MM-USED, M-Arg)

Speaker-aware embeddings

Distinguer signature vocale habituelle vs stratégie de manipulation prosodique

Conclusion

Le véritable verrou n'est pas d'améliorer le score F1 c'est de concevoir des architectures capables de modéliser l'interaction dynamique entre intention paralinguistique et structure logique, ouvrant la voie à une IA capable de comprendre la rhétorique adelà des mots.